

Readme

Μέλη Ομάδας

Δανάη Σκαρλάτου / **2908**

Θοδωρής Δήμας / **2682**

GitHub repository: <https://github.com/ThodorisDimas/InformationRetrievalProject.git>

[A] Συλλογή των εγγράφων

Η συλλογή μας αποτελείται από τις 1000 καλύτερες ταινίες στο διάστημα 2006 έως 2016, σύμφωνα με το www.imdb.com.

Η **πληροφορία** που έχουν (αυτή που θα διατηρηθεί) είναι:

Title : ο τίτλος της ταινίας

Description : η σύντομη περιγραφή της ταινίας

Directors : οι σκηνοθέτες της ταινίας

Actors : οι ηθοποιοί της ταινίας

Year : η χρονιά που κυκλοφόρησε η ταινία

Το **format** των δεδομένων βρίσκεται σε μορφή csv και η πηγή από την οποία αντλήσαμε τα δεδομένα δίνεται παρακάτω.

Πηγή δεδομένων: <https://www.kaggle.com/datasets/PromptCloudHQ/imdb-data>

[B] Σύντομη περιγραφή του σχεδιασμού του συστήματος

[B1] Στόχος και λειτουργικότητας του συστήματος

Στόχος του συστήματος είναι να παρέχει σε έναν χρήστη έναν εύκολο και απλό τρόπο αναζήτησης ταινιών. Μέσα από την εφαρμογή κάποιος θα έχει την δυνατότητα να θέσει αφηρημένα ερωτήματα με απλές λέξεις-κλειδιά είτε να κάνει μία πιο εξειδικευμένη αναζήτηση χρησιμοποιώντας πληροφορίες που μπορεί να αναφέρονται σε συγκεκριμένα στοιχεία των ταινιών. Με την χρήση ενός κατάλληλου γραφικού περιβάλλοντος θα είναι σε θέση να αλληλοεπιδρά με το σύστημα δίνοντας το περιεχόμενο εισόδου στο σύστημα και λαμβάνοντας κατάλληλη έξοδο με τα ζητούμενα αποτελέσματα. Επίσης θα είναι σε θέση να αναδιατάσσει τα αποτελέσματα με διάφορους τρόπους, καθώς και να διατηρεί το ιστορικό των αναζητήσεων του. Τέλος θα παρέχονται και δυνατότητες

[B2] Ανάλυση κειμένου και κατασκευή ευρετηρίου

Για την **προ επεξεργασία** των εγγράφων έχουμε αφαιρέσει ορισμένα πεδία από το dataset που θεωρήσαμε ότι δεν είχαν κάποιο ιδιαίτερο ενδιαφέρον. Έπειτα γίνεται parse του εγγράφου, είναι δομημένο κατάλληλα ώστε να μπορούμε κάθε φορά να δημιουργήσουμε και να εισάγουμε τις πληροφορίες στα document που θα δημιουργήσουμε.

Η **μονάδα εγγράφου** ορίζεται από μία γραμμή στο αρχείο csv και τα αντίστοιχα **πεδία** είναι η πληροφορία όπως την ορίσαμε παραπάνω για το έγγραφο.

Τα έγγραφα θα εισαχθούν στο ευρετήριο του **Index Writer** και με τον **Index Searcher** θα γίνεται η αναζήτηση σε αυτό το ευρετήριο.

Για κάθε ένα από τα πεδία θα δημιουργήσουμε και ένα ευρετήριο για αναζήτηση με χρήση συγκεκριμένης πληροφορίας. Στα **Indexed fields** που αφορούν το description, actors, directors θα υπάρχει **analyzer** για να είναι **tokenized** και είναι **stored**.

[B3] Αναζήτηση

Η αναζήτηση των ταινιών θα γίνεται μέσα από ένα πλαίσιο που θα συμπληρώνει ο χρήστης λέξεις κλειδιά. Δίπλα από το πλαίσιο αυτό θα υπάρχουν εξειδικευμένες επιλογές αναζήτησης και ανάλογα με την επιλογή του χρήστη θα εκτελείται η αντίστοιχη ερώτηση σε συγκεκριμένο πεδίο.

Ο **Query Parser** θα είναι σε θέση ανάλογα με το ερώτημα να κάνει κατάλληλο parse και να υποστηρίζει τα εξής ερωτήματα:

- Περιλαμβάνουν κάποιον όρο
- Περιλαμβάνουν παραπάνω από έναν όρους
- Εμφάνιση όρου σε συγκεκριμένο πεδίο
- Εμφάνιση όρων σε διαφορετικά πεδία
- Ολόκληρες φράσεις με ακρίβεια αναγραφής (Phrase Matches)
- Wild Cards
- Range Matches

Για την δόμηση ερωτημάτων θα υποστηρίζονται και λέξεις κλειδιά με παρόμοια συνάφεια, αυτόματη συμπλήρωση και ορθογραφική διόρθωση καθώς θα πληκτρολογεί και ελέγχει τα αποτελέσματα ο χρήστης.

[B4] Παρουσίαση Αποτελεσμάτων

Τα αποτελέσματα θα παρουσιάζονται ανά 10 (κατά μέγιστο αριθμό) και σε σελίδες. Οι λέξεις όροι που χρησιμοποιήθηκαν στο ερώτημα θα εμφανίζονται έντονα τονισμένες. Το γραφικό περιβάλλον θα παρέχει την δυνατότητα ταξινόμησης των αποτελεσμάτων με διάφορους τρόπους. Πιο συγκεκριμένα σε αριθμητικές τιμές θα επιτρέπεται ταξινόμηση κατά αύξουσα και φθίνουσα σειρά με βάση την τιμή του πεδίου, το ίδιο θα συμβαίνει και λεξικογραφικά σε τιμές με αλφαριθμητικά. Επίσης θα υπάρχει ταξινόμηση με βάση την συνάφεια που απέδωσε το σύστημα στα αποτελέσματα μας. Έπειτα από το parse που θα πραγματοποιήσει ο Query Parser θα λάβουμε ως έξοδο κάποια **ScoreDocs** και έπειτα τα αποτελέσματα που θα διατηρεί που θα διατηρεί ο **TopDocs** θα τα αναδιατάσσουμε κατάλληλα σύμφωνα με τις επιλογές που θα μας έχει ορίσει ο χρήστης.